

Analiza omrežij

V. Batagelj

Kako do

Rodovniki

GraphML

Analiza besedil

Multivariatna

Viri

Analiza omrežij

3. Omrežja vsepovsod

Vladimir Batagelj

Magistrski program Uporabna statistika Ljubljana, april 2024



Kazalo

Analiza omrežij

V. Batageli

Kako do

Rodovniki

Molekule

Analiza besedil

Multivariatna

Kako do omrežja?

Rodovniki

Molekule

GraphML

Analiza besedil

Odnosi med državami

Dvovrstna omrežja

Multivariatna omrežja

Internet

10 Slučajna omrežja

11 Viri

slovenia teletext www.pef.uni-li.si network analysis eclectic.anthrosciences.org www.stumbleupon.com

prof. Vladimir Batagelj: vladimir.batagelj@fmf.uni-lj.si prosojnice (PDF)

22. april 2024 ob 01:15/ marec 2013



Kako do omrežja?

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovniki

Molekule

Graphiv

Analiza besedil

Odnosi med državami

omrežja

omrežja

Internet

Slučajna omrežja

\ /:..:

Pri zbiranju podatkov o omrežju $\mathcal{N}=(\mathcal{V},\mathcal{L},\mathcal{P},\mathcal{W})$ se moramo odločiti, kaj je množica enot (vozlišč) – *meje omrežja*, kdaj sta vozlišči povezani – *polnost omrežja* in katere lastnosti vozlišč/povezav bomo upoštevali.

Ta vprašanja so še posebej pereča pri merjenju družbenih omrežij (vprašalniki, pogovori, opazovanja, arhivski zapiski, poskusi, ...). Nekatere 'enote' nočeje sodelovati. Nekateri postopki merjenja, na primer, omejujejo število sosedov ... Naslednja velika ovira pri izgradnji teh omrežij je spoštovanje zasebnosti. Pri tem si pri velikih množicah enot ne moremo privoščiti polnega opisa. Omrežje izmerimo samo za izbrane enote (in njihove sosede). Tako dobljena omrežja imenujemo *osebna omrežja*. O merjenju družbenih omrežij si lahko preberete v knjigi V. Hlebec in T. Kogovšek (2006).

V zadnjih 20 letih vsebolj pridobivamo omrežja iz podatkovij, ki so že dostopna na računalniku ((spletne) podatkovne baze, dnevniki uporabe, družabna omrežja, ...).



Cela in osebna omrežja

Analiza omrežij

V. Batagelj

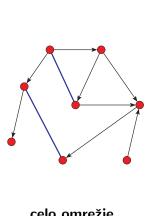
Kako do omrežja?

GraphML

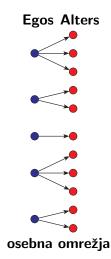
Analiza besedil

Multivariatna

Viri









Uporaba že zbranih omrežij

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovniki

Molekule

GraphM

Analiza besedil

Odnosi med

državami -

Multivariatr omrežia

Interne

Slučajna omrežja Pajek omogoča branje več drugih oblik opisa omrežij: UCINETove datoteke DL, grafi projekta Vega, kemični opisi molekul MDLMOL, MAC in BS ter rodovniki v obliki GEDCOM.

Davis.DAT, C84N24.VGR, MDL, 1CRN.BS, DNA.BS, ADF073.MAC, Bouchard.GED.

Večkrat pa je potrebno dani opis omrežja le nekoliko popraviti (dodati določila *vertices, *arcs,...; zamenjati vozlišče 0 s pozitivnim številom) v znakovnem urejevalniku in ga tako predelati v zahtevano obliko.

Za nekoliko zahtevnejše predelave poglejte Jürgen Pfeffer: txt2pajek.



Krebsova Internetska podjetja

Analiza omrežij

V. Batageli

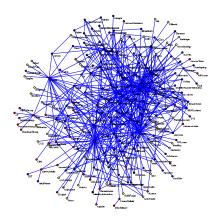
Kako do omrežja?

Rodovniki

Molekule

Analiza besedil

Viri



Omrežje sestavljajo izbrana Internetska podjetja v obdobju 1998 do 2001. n = 219, m = 631.rdeča – vsebina. modra – podpora, rumena - trgovina. Podjetji sta povezani, če sta objavili skupni posel ali sode-

Spletni naslov: http://www.orgnet.com/netindustry.html. Recode, InfoRapid.

lovanje.



Rodovniki

Analiza omrežij V. Batagelj

Kako do

Rodovniki

Molekule

Analiza besedil

Za opis rodovnikov se najpogostoje uporablja oblika zapisa GEDCOM (GEDCOM standard 5.5).

Veliko rodovnikov (datoteke *.GED) najdemo na spletu – na primer Roper's GEDCOMs, Genealogy Forum GEDCOMs, KinSource ali Isle-of-Man GEDCOMs Family.GED.

Za pripravo in vzdrževanje rodovnikov je na voljo več programov: prosti GIM in tržni Brothers Keeper (obstaja tudi slovenska različica - *SRD*).

Iz rodovnikov zbranih v doktoratu: Mahnken, Irmgard. 1960. Dubrovački patricijat u XIV veku. Beograd, Naučno delo. je bilo ustvarjeno podatkovje Ragusa.



GEDCOM

Analiza omrežij

V. Batagelj

Kako do

Rodovniki

Odnosi med

Multivariatna

GEDCOM je dogovor o zapisu rodoslovnih podatkov, ki se uporablja za izmenjavo in združevanje podatkov iz različnih programov uporabljenih za pripravo podatkov.

```
O HEAD
                                            0 @I115@ INDI
1 FILE ROYALS.GED
                                            1 NAME William Arthur Philip/Windsor/
                                            1 TITL Prince
0 @158@ INDI
                                            1 SEX M
1 NAME Charles Philip Arthur/Windsor/
1 TITL Prince
                                            1 BIRT
                                            2 DATE 21 JUN 1982
1 SEX M
                                            2 PLAC St. Mary's Hospital, Paddington
1 BIRT
                                            1 CHR
2 DATE 14 NOV 1948
                                            2 DATE 4 AUG 1982
2 DATE 14 NUV 1948 2 PLAC Buckingham Palace, London 2 PLAC Music Room, Buckingham Palace
2 DATE 15 DEC 1948
2 PLAC Buckingham Palace, Music Room
1 FAMS @F16@
                                            0 @I116@ INDI
                                            1 NAME Henry Charles Albert/Windsor/
1 FAMC @F14@
                                            1 TITL Prince
                                            1 SEX M
                                           1 BIRT
                                            2 DATE 15 SEP 1984
0 @165@ INDI
1 NAME Diana Frances /Spencer/
                                            2 PLAC St.Mary's Hosp., Paddington
1 FAMC @F16@
1 TITL Lady
1 SEX F
1 BIRT
2 DATE 1 JUL 1961
2 PLAC Park House, Sandringham
                                           1 WIFE @165@
                                           1 CHIL @I115@
1 CHR
2 PLAC Sandringham, Church
1 FAMS @F16@
                                          1 CHIL @I116@
                                           1 DIV N
1 FAMC 0F780
                                            1 MARR
                                            2 DATE 29 JUL 1981
                                            2 PLAC St. Paul's Cathedral, London
```



Omrežne predstavitve rodovnikov

Analiza omrežij

V. Batagelj

Kako do omrežja

Rodovniki

Molekule

GrapiliviL

Analiza besedil

Odnosi med

Dvovrstna

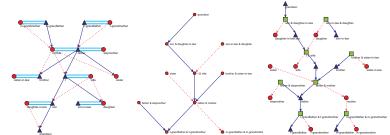
Multivariatn omrežja

Interne

Slučajn omrežja

omrežj

Običajna predstavitev rodovnika z grafom, *Ore*jev graf, ima za vozlišča posameznike in združuje dve relaciji: *sta poročena* (modro-bela neusmerjena) in *ima otroka* (usmerjena), razbita na *je oče od* (modra) in *je mati od* (črtkana rdeča). V *parnem grafu* so vozlišča poročeni pari ali neporočeni posamezniki, in relaciji *je sin* (polna modra) in *je hči* (črtkana rdeča). Več o parnih grafih *D. White*.



Orejev graf, parni graf in dvodelni parni graf



Omrežja molekul

Analiza omrežij

V. Batageli

Rodovniki

Molekule

Analiza besedil

virus 1GDY: n = 39865. m = 40358

V zbirki Brookhaven Protein Data Bank lahko najdemo veliko velikih organskih molekul (npr. Simian / 1AZ5.pdb) opisanih v obliki PDB. Molekulo si lahko ogledamo s programom Rasmol (RasMol, program, RasWin) ali Protein Explorer. Molekulo v obliki PDB lahko prede-

lamo v obliko BS, ki jo pozna Pajek, s programom BabelWin + Babel16.

Koristno bi bilo imeti podoben program za splošna omrežja.



${\sf GraphML}$

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovniki

Molekule

 $\mathsf{GraphML}$

Analiza besedil

Odnosi med državami

omrežja Multivariat

Internet

Interne

omrežj:

\/iri

GraphML – zapis omrežja v obliki XML.

L'Institut de Linguistique et Phonétique Générales et Appliquées (ILPGA), Paris III; Traitement Automatique du Langage (TAL):

BaO4: Des Textes Aux Graphes Plurital

LibXML, xsltproc download, XSLT, Xalan, Python, Sxslt.

xsltproc GraphML2Pajek.xsl graph.xml > graph.net
java -jar saxon8.jar graph.xml GraphML2Pajek.xsl > graph.net
java org.apache.xalan.xslt.Process -IN p.xml -XSL m.xsl -OUT p.tx

XSLT/Zvon

```
<?xml version="1.0" encoding="UTF-8"?>
                                                                                  *Vertices 12
<!-- Title: 1. D:\vlado\docs\Books\SKRIPTA\Nets\nets\graph.net (12) -->
                                                                                  1 "a"
<!-- Creator: Pajek: http://vlado.fmf.uni-li.si/pub/networks/pajek/ -->
                                                                                  2 "h"
                                                                                  3 """
<!-- CreationDate: 11-03-2006, 17:25:13 -->
                                                                                  4 "å"
<graphml>
  <kev id="a1" for="node" attr.name="Label" attr.type="string">
                                                                                  5 "e"
    <desc>Label of the node</desc> <default>NoLabel</default>
                                                                                  6 "f"
                                                                                  7 "g"
  </kev>
  <kev id="b1" for="edge" attr.name="Weight" attr.type="double">
                                                                                  8 "h"
    <desc>Weight (value) of the edge</desc> <default>1</default>
                                                                                  9 "i"
                                                                                  10 "i"
  </kev>
  <graph id="G" edgedefault="directed" parse.nodes="12" parse.edges="23">
                                                                                  11 "k"
    <node id="v1"><data kev="a1">a</data></node>
                                                                                  12 "1"
    <node id="v2"><data key="a1">b</data></node>
                                                                                  *Edges
    <node id="v3"><data kev="a1">c</data></node>
                                                                                  2.5
    <node id="v4"><data key="a1">d</data></node>
                                                                                  3 4
    <node id="v5"><data key="a1">e</data></node>
                                                                                  5 7
    <node id="v6"><data kev="a1">f</data></node>
                                                                                  6 8
    <node id="v7"><data key="a1">g</data></node>
                                                                                  *Arcs
    <node id="v8"><data key="a1">h</data></node>
                                                                                  1 2
    <node id="v9"><data kev="a1">i</data></node>
                                                                                  2 1
    <node id="v10"><data key="a1">j</data></node>
                                                                                  1 4
                                                                                  1 6
    <node id="v11"><data key="a1">k</data></node>
    <node id="v12"><data kev="a1">1</data></node>
                                                                                  2 6
    <edge source="v1" target="v2"/> <edge source="v2" target="v1"/>
                                                                                  3 2
    <edge source="v1" target="v4"/> <edge source="v1" target="v6"/>
                                                                                  3 3
    <edge source="v2" target="v6"/> <edge source="v3" target="v2"/>
                                                                                  3 7
    <edge source="v3" target="v3"/> <edge source="v3" target="v7"/>
                                                                                  3 7
    <edge source="v3" target="v7"/> <edge source="v5" target="v3"/>
                                                                                  5.3
    <edge source="v5" target="v6"/> <edge source="v5" target="v8"/>
                                                                                  5 6
    <edge source="v6" target="v11"/> <edge source="v8" target="v4"/>
                                                                                  5 8
    <edge source="v10" target="v8"/> <edge source="v12" target="v5"/>
                                                                                  6 11
    <edge source="v12" target="v7"/> <edge source="v8" target="v12"/>
                                                                                  8 4
    <edge source="v12" target="v8"/>
                                                                                  10.8
    <edge directed="false" source="v2" target="v5"/>
                                                                                  12.5
    <edge directed="false" source="v3" target="v4"/>
                                                                                  12.7
    <edge directed="false" source="v5" target="v7"/>
                                                                                  8 12
    <edge directed="false" source="v6" target="v8"/>
                                                                                  12.8
  </graph>
</graphml>
```

```
<?xml version="1.0" encoding="iso-8859-1"?>
<xsl:stylesheet version="1.0" xmlns:xsl="http://www.w3.org/1999/XSL/Transform">
  <xsl:output method="text" encoding="iso-8859-1"/>
  <xsl:template match="/">
    <xsl:text>*Vertices </xsl:text>
    <xsl:value-of select="count(graphml/graph/node)"/>
    <xsl:text>&#10:</xsl:text>
    <xsl:apply-templates select="graphml/graph/node"/>
    <xsl:text>*Edges&#10;</xsl:text>
    <xsl:apply-templates select="graphml/graph/edge" mode="edge"/>
    <xsl:text>*Arcs&#10:</xsl:text>
    <xsl:apply-templates select="graphml/graph/edge" mode="arc"/>
  </xsl:template>
  <xsl:template match="edge" mode="arc">
    <xsl:if test="not(./@directed='false')">
      <xsl:value-of select="substring(./@source.2)"/>
      <xsl:text> </xsl:text>
     <xsl:value-of select="substring(./@target.2)"/>
      <xsl:text> </xsl:text>
     <xsl:value-of select="./data"/>
      <xsl:text>&#10;</xsl:text>
    </xsl:if>
  </xsl:template>
  <xsl:template match="edge" mode="edge">
    <xsl:if test="./@directed='false'">
      <xsl:value-of select="substring(./@source.2)"/>
      <xsl:text> </xsl:text>
      <xsl:value-of select="substring(./@target,2)"/>
      <vsl:text> </vsl:text>
      <xsl:value-of select="./data"/>
     <xsl:text>&#10;</xsl:text>
    </r>
  </xsl:template>
  <xsl:template match="node">
    <xsl:value-of select="substring(./@id.2)"/>
    <xsl:text> "</xsl:text>
    <xsl:value-of select="./data"/>
    <xsl:text>"&#10:</xsl:text>
  </xsl:template>
</xsl:stvlesheet>
```



Pristopi k računalniško podprti analizi besedil

Analiza omrežij

V. Batageli

Kako do

Molekule

Analiza besedil

R. Popping: Computer-Assisted Text Analysis (2000) razlikuje tri glavne pristope k RPAB: tematska AB, pomenska AB, in omrežna AB.

Pojmi (besede, besedne zveze, izrazi, ...) upoštevani pri AB so zbrani v *slovarju*. Ta je lahko določen vnaprej ali pa se gradi sproti. Osnovni vprašanji pri tem sta *enakovrednost zapisov* – različni zapisi, ki predstavljajo isti pojem; in *dvoumnost zapisov* – isti zapis lahko predstavlja več pojmov. Poskusi rešitve: za imena: ResearcherID, ORCID, AMS; za besede: krnjenje (stemming) in geslenje (lemmatization).

Zato je kodiranje – pretvorba surovih podatkov v formalni opis, pogosto opravljeno pretežno ročno ali vsaj pod nadzorom uporabnika. Kot enote AB ponavadi vzamemo stavke, odstavke, novice, sporočila,

Dosedaj sta tematska in pomenska AB temeljili predvsem na statistični analizi kodiranih podatkov.



... pristopi k RPAB

Analiza omrežij V. Batageli

Kako do

Rodovniki

Molekule

Analiza besedil

Pri tematski AB so enote besedila kodirane s pravokotno matriko Enote \times Pojmi : pojem p se pojavlja v enoti e – dvovrstno omrežje. Primeri: M.M. Miller: VBPro, H. Klein: Text Analysis/ TextQuest. Pri pomenski AB so enote (največkrat enostavni stavki) kodirane po shemi o-P-p (osebek-Povedek-predmet) ali njenih izpeljankah.



Primeri: Roberto Franzosi; KEDS, Tabari.

To kodiranje določa večrelacijsko omrežje na množici vozlišč *Osebki* ∪ *Predmeti* s povezavami iz relacij *Povedki*.

Gleite tudi RDF v pomenskem spletu (semantic web), SPARQL.



Omrežna RPAB

Analiza omrežij

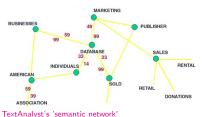
V. Batageli

Kako do

Rodovniki

Molekule

Analiza besedil



Tako smo že v omrežni AR

Primeri:

Carley: Cognitive maps, J.A. de Ridder: CETA.

Megaputer: TextAnalyst.

Gleite še: W. Evans: Computer Environments for Content Analysis, K.A. Neuendorf: The Content Analysis Guidebook / Online and H.D.

White Publications

Obstajajo tudi drugi načini, kako ustvariti omrežja iz besedil.



AB – slovarska omrežja

Analiza omrežij

V. Batagelj

Kako do omrežja?

Kodovnii

Moleku

Grapilivi

Analiza besedil

državami

Multivariatn

Interne

Slučajn omrežja

,

book

A collection of leaves of paper, parchment, yellun, cloth, or other material (written, printed, or blank) fastened together along one edge, with or without a protective <u>case</u> or <u>cover</u>. Also refers to a literary <u>work</u> or one of its <u>yolumes</u>. Compare with <u>monor appl.</u>

To qualify for the special parcel post rate known in the United States as media rate, a publication must consist of 24 or more pages, at least 22 of which bear printing consisting primarily of reading material or scholarly bibliography, with advertising limited to book amountements. UNESCO defines a book as a nonperiodical literary publication consisting of 49 or more pages, covers excluded. The ANSI standard includes publications of less than 49 pages which have hard covers. See also at book, board book, children's book, coffee table book, gift book, licensed book, managed book, new book, packaged book, picture book, premium book, professional book, promotional book, rare book, reference book, religious book, and reprint book.

Also, a major division of a longer work (usually of fiction) which is further subdivided into <u>chapters</u>. Usually <u>numbered</u>, such a division may or may not have its own <u>title</u>. Also refers to one of the divisions of the Christian *Bible*, the first being *Genetis*.

V *slovarskem omrežju* so vozlišča v slovarju opisani pojmi; iz pojma *u* vodi povezava do pojma *v* ntk. pojem *v* nastopa v opisu pojma *u*.

Online Dictionary of Library and Information Science *ODLIS*, *Odlis.net* (2909 / 18419).

Free On-line Dictionary of Computing *FOLDOC*, *Foldoc2b.net* (133356 / 120238).

Artlex, Wordnet, ConceptNet, OpenCyc.

opis pojma book v ODLIS

The Edinburgh Associative Thesaurus (*EAT*) / *net* je bil zbran s spraševanjem (študentov).

NASA Thesaurus. Paper.



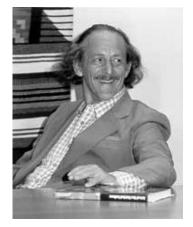
AB – Omrežja sklicevanj

Analiza omrežij

V. Batageli

Rodovniki

Analiza besedil



V omrežju sklicevanj so vozlišča razna dela (članki, knjige, poročila, ...) iz izbranega področja; deli sta povezani z usmerjeno povezavo, če se prvo sklicuje na drugo. Omrežja sklicevanj so (skoraj) aciklična. E. Garfield: HistCite / Pajek, pa-

pers.

Primer zelo velikega omrežja sklicevanj je US Patents / Nber, n = 3774768, m = 16522438.extended data



AB – Omrežja sodelovanj

Analiza omrežij

V. Batageli

Rodovniki

Molekule

Analiza besedil

V omrežiih sodelovani so enote osebe ali ustanove. Enoti sta povezani, če sta sodelovali pri skupnem delu. Utež povezave je število skupnih del.

Najbolj poznano omrežje sodelovanja je The Erdős Number Project, Erdos.net. Določitev Erdősevega števila.

Bogat vir podatkov za izgradnjo omrežij sodelovanj so bibliografije v BibTFXu Nelson H. F. Beebe's Bibliographies Page - primer B. Jones-ova bibliografija računalniške geometrije Computational geometry database (2002), FTP, Geom.net. Pri pripravi omrežja sodelovanj iz izvornih podatkov si lahko pomagamo z ustreznimi programi. Nato pa sledi mukotrpno čiščenje - ugotavljanje enot.

Glejte tudi: The Internet Movie Database; Trier DBLP: Digital Bibliography & Library Project; 1124. sredin seminar. Omrežja sklicevanj in sodelovanj je mogoče dobiti iz Web of Science z WoS2Pajek. Glejte še Bibexcel.



Odnosi med državami

Analiza omrežij

V. Batagelj

Kako do

Rodovniki

Molekule

Analiza besedil

Odnosi med državami

Viri

Paul Hensel's International Relations Data Site. International Conflict and Cooperation Data, Correlates of War. Kansas Event Data System KEDS, KEDSi na Pajkovih datotekah, Prekodirni programi v R-ju.



Pretvorba podatkov KEDS/WEIS v Pajekovo obliko

Analiza omrežij

V. Batagelj

Kako do

Rodovnik

Molekul

GraphM

Analiza bes

Odnosi med

Dvovrstna

Multivariatna

Internet

Slučajna omrežja

```
% Recoded by WEISmonths, Sun Nov 28 21:57:00 2004
% from http://www.ku.edu/~keds/data.dir/balk.html
*vertices 325
  "AFG" [1-*]
  "AFR"
  "ALB" [1-*
  "ALBMED" [1-*]
  "ALG" [1-*]
    "YUGGOV"
    "YUGMAC"
                Γ̃1−*
    "YUGMTN"
                Γ1−*<sup>†</sup>
    "YUGSER"
    "ZAM"
            Γ̃1−*
          "*** ABANDONED"
           "YIELD"
           "SURRENDER"
*arcs :11
*arcs :12 "RETREAT
*arcs : 223 "MIL ENGAGEMENT'
       :224 "RIOT"
       :225 "ASSASSINATE TORTURE"
*arcs
224: 314 153 1 [4]
                                                 YUG
                                                                    224
                                                                           (RIOT)
                                        890402
                                                           KSV
                                                                                    RIOT-TORN
212: 314 83 1 [4]
224: 3 83 1 [4]
123: 83 153 1 [4]
                                        890404
                                                 YUG
                                                           ETHALB
                                                                    212
                                                                           (ARREST PERSON) ALB ETHNIC JAILEI
                                        890407
                                                 ALB
                                                           ETHALB
                                                                           (RIOT)
                                                                    224
                                                                                   RIOTS
                                                 ETHALB
                                                                           (INVESTIGATE)
                                        890408
                                                           KSV
                                                                    123
                                                                                             PROBING
42: 105 63 1 [175]
                                        030731
                                                 GER.
                                                           CYP
                                                                    042
                                                                           (ENDORSE)
                                                                                             GAVE SUPPORT
212: 295 35 1 [175]
                                        030731
                                                                    212
                                                                                             SENTENCED TO PRIS
                                                 UNWCT
                                                           BOSSER
                                                                           (ARREST PERSON)
43: 306 87 1 [175]
13: 295 35 1 [175]
                                        030731
                                                 VAT
                                                           EUR
                                                                    043
                                                                           (RALLY) RALLIED
                                        030731
                                                 UNWCT
                                                           BOSSER
                                                                    013
                                                                           RETRACT)
                                                                                             CLEARED
121: 295 22 1 [175]
122: 246 295 1 [175]
                                        030731
                                                 UNWCT
                                                           BAL
                                                                    121
                                                                           (CRITICIZE)
                                                                                             CHARGES
                                        030731
                                                           UNWCT
                                                                    122
                                                  SER
                                                                           (DENIGRATE)
                                                                                             TESTIFIED
121: 35 295 1 [175]
                                        030731
                                                 BOSSER
                                                           UNWCT
                                                                    121
                                                                                              ACCUSED
```



Analiza omrežij

V. Batagelj

Kako do omrežia?

Rodovniki

NA - L-L--L-

GraphML

Analiza besedil

Odnosi med

državami Dvovrstna

Multivariatna omrežia

Internet

Slučajna omrežja

Viri

... Program v R-ju

WEISmonths

Za pretvorbo podatkov KEDS/WEIS smo uporabili kratke programe v R-ju, kot je naslednji:

```
granularity is 1 month
 Vladimir Batagelj, 28. November 2004
# Usage:
   WEISmonths(WEIS file, Pajek file)
# Examples:
   WEISmonths('Balkan.dat', 'BalkanMonths.net')
 http://www.ku.edu/~keds/data.html
WEISmonths <- function(fdat,fnet){
 get.codes <- function(line){
   nlin <<- nlin + 1:
   z \leftarrow unlist(strsplit(line,"\t")); z \leftarrow z[z != ""]
   if (length(z)>4) {
     t \le as.numeric(z[1]): if (t \le 500000) t \le t + 1000000
      if (t<t0) t0 <<- t; u <- z[2]; v <- z[3]; r <- z[4]
     if (is.na(as.numeric(r))) cat(nlin,'NA rel-code',r,'\n')
     h \leftarrow z[5]; h \leftarrow substr(h,2,nchar(h)-1)
     if (nchar(h) == 0) h <- '*** missing description'
     if (!exists(u.env=act.inherits=FALSE)){
        nver <<- nver + 1: assign(u.nver.env=act) }
     if (!exists(v.env=act.inherits=FALSE)){
        nver <<- nver + 1: assign(v.nver.env=act) }
     if (!exists(r,env=rel,inherits=FALSE)) assign(r,h,env=rel)
                                                          4 D > 4 A > 4 B > 4 B >
```

recoding of WEIS files into Pajek's multirelational temporal files

```
recode <- function(line){
    nlin <<- nlin + 1:
    z <- unlist(strsplit(line,"\t")); z <- z[z != ""]</pre>
    if (length(z)>4) {
      t \le as.numeric(z[1]): if (t \le 500000) t \le t + 1000000
      cat(as.numeric(z[4]),': ',get(z[2],env=act,inherits=FALSE),
        ' ',get(z[3],env=act,inherits=FALSE),' 1 [',
        12*(1900 + t \%/\% 10000) + (t \%\% 10000) \%/\% 100 - t0
        ']\n',sep='',file=net)
 cat('WEISmonths: WEIS -> Pajek\n')
 ts <- strsplit(as.character(Sys.time()), " ")[[1]][2]
 act <- new.env(TRUE.NULL); rel <- new.env(TRUE.NULL)
 dat <- file(fdat, "r"): net <- file(fnet, "w")
 lst <- file('WEIS.lst', "w"): dni <- 0
 nver <- 0; nlin <- 0; t0 <- 9999999
  lines <- readLines(dat); close(dat)
  sapply(lines,get.codes)
  a <- sort(ls(envir=act)); n <- length(a)
  cat(paste('% Recoded by WEISmonths,',date()),"\n",file=net)
  cat("% from http://www.ku.edu/~keds/data.html\n",file=net)
 cat("*vertices",n,"\n",file=net)
 for(i in 1:n){ assign(a[i].i.env=act):
    cat(i, ' "', a[i], '" [1-*]\n', sep='', file=net) }
  b <- sort(ls(envir=rel)): m <- length(b)
 for(i in 1:m){ assign(a[i].i.env=act):
 cat("*arcs:",as.numeric(b[i]),' "',
  get(b[i],env=rel,inherits=FALSE),'"\n',sep='',file=net) }
  t0 <- 12*(1900 + t0 %/% 10000)
  slice <- 0
 cat("*arcs\n".file=net): nlin <- 0
 sapply(lines.recode)
 cat(' ',nlin,'lines processed\n'); close(net)
 te <- strsplit(as.character(Sys.time()), " ")[[1]][2]
 cat(' start:',ts,' finish:',te,'\n')
WEISmonths('Balkan.dat', 'BalkanMonthsR.net')
```

Opomba: Slovariem (dictionary) se v R-iu reče environment.



Dvovrstna omrežja iz podatkovnih baz

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovnik

Molekule

Grapilivic

Analiza besedil

Odnosi med državami Dvovrstna

omrežja Multivariatna

Offirezja

Interne

Slučajna omrežja

\/iri

Enostavno $podatkovno\ bazo\ \mathcal{B}$ sestavlja množica zapisov

 $\mathcal{B} = \{R_k : k \in \mathcal{K}\}$, kjer je \mathcal{K} množica *ključev*. Posamezni zapis ima obliko $R_k = (k, q_1(k), q_2(k), \dots, q_r(k))$ kjer je $q_i(k)$ opis/vrednost *lastnosti* \mathbf{q}_i za enoto določeno s ključem k.

Naj opis q(k) zavzema vrednosti v končni množici \mathcal{Q} . Tak opis lahko vselej zagotovimo z diskretizacijo množice \mathcal{Q} . Potem lahko za izbrano lastnost \mathbf{q} ustvarimo pripadajoče *dvovrstno omrežje* $\mathcal{K} \times \mathbf{q} = (\mathcal{K}, \mathcal{Q}, \mathcal{L}, w)$, kjer je $(k, v) \in \mathcal{L}$ ntk $v \in q(k)$. w(k, v) je utež na povezavi (k, v); če ni drugače določeno, postavimo w(k, v) = 1.

Lastnosti z eno samo vrednostjo lahko varčneje predstavimo z razbitjem.

Primeri:

(članki, avtorji, je bil soustvarjen od), (članki, ključne besede, je opisan z), (poslanci, zakoni, je glasoval za), (ljudje, časopisi, bere), (ljudje, združenja, je član, število let članstva), (kupci, dobrine, je kupil, vrednost), itd.



Zapis z Web of Science

Analiza omrežij

V. Batageli

Analiza besedil

Dvovrstna omrežia

GA 105IIP

UT 1S1:000075092200008

```
PT J
AU Dipple, H
   Evans, B
TI The Léicestershire Huntington's disease support group: a social network
   analysis
SO HEALTH & SOCIAL CARE IN THE COMMUNITY
LA English
DT Article
C1 Rehabil Serv, Troon Way Business Ctr, Leicester LE4 9HA, Leics, England.
RP Dipple, H, Rehabil Serv, Troon Way Business Ctr, Sandringham
   Suite, Humberstone Lane, Leicester LE4 9HA, Leics, England.
CR BORGATTI SP, 1992, UCINET 4 VERSION 1 0
FOLSTEIN S, 1989, HUNTINGTONS DIS DISO
   SCOTT J, 1991, SÓCIAL NETWORK ANAL
NR 3
TC 3
PU BLACKWELL SCIENCE LTD
PA P O BOX 88, OSNEY MEAD, OXFORD OX2 ONE, OXON, ENGLAND
SN 0966-0410
J9 HEALTH SOC CARE COMMUNITY
JI Health Soc. Care Community
PD JUI.
PY 1998
VI. 6
IS 4
BP 286
EP 289
PG 4
SC Public, Environmental & Occupational Health: Social Work
```



Program WoS2Pajek

Analiza omrežij

V. Batageli

Molekule

Analiza besedil

Dvovrstna omrežja

Za pretvorbo datotek z WoS v nabor Pajkovih omrežij je bil v Pythonu napisan program WoS2Pajek, ki ustvari naslednje datoteke:

- omrežje sklicevanj: dela × dela;
- omrežje avtorstev (dvovrstno): dela × avtorji; za dela brez polnih opisov je znan le prvi avtor;
- omrežje ključnih besed (dvovrstno): dela × ključne besede; samo za dela s polnimi opisi;
- omrežje revij (dvovrstno): dela × revije polje J9;
- razbitje del glede na leto objave;
- razbitje del polni opis (1) / samo ime ISI (0);
- vektor s številom strani za posamezno delo PG ali EP BP +1.

Podoben paket je pripravil tudi Loet Leydesdorff.



Omrežja sosednjih vozlišč

Analiza omrežij

V. Batageli

Analiza besedil

Multivariatna omrežia

Recimo, da imamo na množici enot \mathcal{U} dano mero različnosti d(u, v). Glede na d lahko vpeljemo dve vrsti omrežij:

k-najbližjih sosedov: $\mathcal{N}(k) = (\mathcal{U}, \mathcal{A}, d)$

 $(u, v) \in \mathcal{A} \Leftrightarrow v$ je med k najbližjimi sosedi vozlišča u

Za utež povezave $a(u, v) \in \mathcal{A}$ postavimo w(a) = d(u, v).

Omrežje r-okolic: $\mathcal{N}(r) = (\mathcal{U}, \mathcal{E}, d)$

$$(u:v) \in \mathcal{E} \Leftrightarrow d(u,v) \leq r$$

Za utež povezave $e(u:v) \in \mathcal{E}$ postavimo w(e) = d(u,v).

Ta omrežja so povezava z običajno analizo podatkov. Še vedno odprto vprašanje: učinkoviti postopki za določanje teh omrežij. Multivariatne pajčevine – določitev omrežij sosedov v R-ju.



Najbližjih k sosedov v R-ju

Analiza omrežij

V. Batagelj

Kako do

Molekule

Analiza besedil

Multivariatna omrežia

```
k.neighbor2Net <-
# stores network of first k neighbors for
# dissimilarity matrix d to file fnet in Pajek format.
function(fnet,d,k){
  net <- file(fnet,"w")</pre>
  n <- nrow(d); rn <- rownames(d)</pre>
  cat("*vertices",n,"\n",file=net)
  for (i in 1:n) cat(i,"'\",rn[i],"\"\n",sep="",file=net)
  cat("*arcs\n",file=net)
  for (i in 1:n) for (j in order(d[i,])[1:k+1]) {
    cat(i,j,d[i,j],"\n",file=net)
  close(net)
stand <-
# standardizes vector x .
function(x){
  s \leftarrow sd(x)
  if (s > 0) (x - mean(x))/s else x - x
data(iris)
ir <- cbind(stand(iris[,1]),stand(iris[,2]),stand(iris[,3]),</pre>
  stand(iris[,4]))
k.neighbor2Net("iris5.net",as.matrix(dist(ir)),5)
                                       4 D > 4 A > 4 B > 4 B >
```



Hitri postopek za najbližjih k sosedov v R-ju

Analiza omrežij

V. Batageli

Kako do

Molekule

Analiza besedil

Multivariatna omrežia

David M. Mount ie ustvaril Approximate Nearest Neighbor Library (http://www.cs.umd.edu/~mount/ANN), ki vsebuje hitre algoritme za (približno) določitev najbližjih sosedov. V R-ju so ti algoritmi dostopni s funkcijo ann v kniižnici vaImpute.

```
k.neighbor2NetF <-
# stores network of first k neighbors for data matrix d to file fnet
# in Pajek format.
# Example:
   data(iris): stand <- function(x){(x-mean(x))/sd(x)}</pre>
  ir <- cbind(stand(iris[,1]),stand(iris[,2]),stand(iris[,3]).</pre>
      stand(iris[.4]))
   k.neighbor2NetF("iris5Y.net",ir.5)
# V. Batagelj, 8.8.2009 yaImpute / 9.9.2008 knnFinder
function(fnet.d.k){
 library(vaImpute)
 NN <- ann(ir,target=ir,k=k+1)
 net <- file(fnet."w")</pre>
  n <- nrow(d)
 rn <- if (is.null(rownames(d))) paste("U-",1:n,sep='') else rownames(d)
 cat("*vertices",n,"\n",file=net)
 for (i in 1:n) cat(i," \"",rn[i],"\"\n",sep="",file=net)
 cat("*arcs\n".file=net)
 for (i in 1:n) for (i in 1:k)
    cat(i,NN$knnIndexDist[i,j+1],NN$knnIndexDist[i,j+k+2],"\n",file=net)
 close(net)
```



Fisherjeve perunike z dodatnimi podatki

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovniki

Molekule

Analiza besedil

Odnosi med

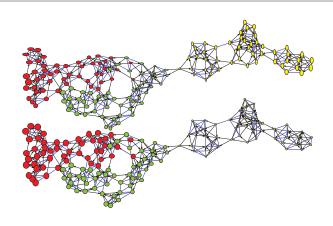
Dvovrstn

Multivariatna omrežja

IIILEITIE

omrežja

Viri



Draw/Network+First Partition+First Vector+Second Vector Velikost vozlišč je sorazmerna normaliziranima (Sepal.Length, Sepal.Width) oziroma (Petal.Length, Petal.Width). Barva vozlišč je določena z razbitjem iz podatkov. Podatki.



r-sosedi v R-ju

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovnik

Molekule

GrapiliviL

Analiza besedil

Odnosi med

Dvovrstna

Multivariatna omrežia

Internet

Slučajni omrežja

omrez

```
r.neighbor2Net <-
# stores network of r-neighbors (d(v,u) \le r) for
# dissimilarity matrix d to file fnet in Pajek format.
function(fnet,d,r){
  net <- file(fnet,"w")</pre>
  n <- nrow(d); rn <- rownames(d)
  cat("*vertices",n,"\n",file=net)
for (i in 1:n) cat(i," \"",rn[i],"\n",sep="",file=net)
  cat("*edges\n",file=net)
  for (i in 1:n){
    s <- order(d[i,]); j <- 1
    while (d[i,s[j]] \leq r) {
      k \leftarrow s[j]; if (i < k) cat(i,k,d[i,k],"\n",file=net)
      j <- j+1
  close(net)
```



Transformacije

Analiza omrežij

V. Batageli

Kako do

Rodovniki

Molekule

Analiza besedil

Multivariatna

omrežia

Besedni graf – vozlišča so besede; besedi sta povezani, če lahko eno dobimo iz druge s spremembo ene črke. DIC28, Članek.

Omrežja iz besedil – besedi sta povezani, če se v besedilu pojavita dovolj blizu skupaj. Utež povezave je število takih ponovitev. Primer CRA.

Grafi iger – vozlišča so stanja v igri, povezave pa dovoljeni prehodi med njimi. Omrežja in zabavna matematika.

Z zbiranjem podatkov o mobilnih telefonih ali s spremljanjem značk RFID (Radio-frequency identification) lahko ustvarjamo omrežja (so)delovanj njihovih lastnikov.



Internetska omrežja

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovniki

Moleku

Grapilivic

Allaliza Deseul

državami

Dvovrstna omrežia

Multivariatn omrežja

Internet

Slučajn omrežja

\/iri



Internet Mapping Project.

Sosednost na spletu (Najdi.si).

E-mail, blogi, strežniški dnevniki in druge storitve.

Povezave med stranmi na spletu: KartOO, Touch-Graph.

Cybergeography, CAIDA.
Orodia za pridobivanje p

Orodja za pridobivanje podatkov s spleta: *MedlineR*, *SocSciBot*.

KartOO network

Pomenski splet (URI, RDF, OWL). LOD, FreeBase, DBpedia.



Rabutanie

Analiza omrežij

V. Batageli

Kako do

Rodovniki

Molekule

Analiza besedil

Internet

Za pridobivanje izbranih podatkov iz (večih) spletnih strani lahko napišemo posebne programe web wrappers. Ti iz posamezne strani izluščijo iskane podatke in jih shranijo – pogosto v obliki XML.

Primeri v R-ju: Naslovi patentov, Knjige z Amazon.

Ker je pisanje teh programov za običajnega uporabnika prezapleteno, je bilo razvitih več *orodij*, ki jih ustvarijo iz uporabnikovih opisov/zahtev (članek / seznam / LAPIS).

Med prostimi orodji sta zanimiva še XWRAP (opis / stran) in TSIMMIS (opis / stran).

Med tržnimi orodji trenutno prevladuje lixto.

Še nekaj naslovov 1, 2, 3.

Nutch, IssueCrawler, W4F.

Python: |xml: nadgradnja etree, dostop do najboljših knjižnic; nadgradnja Beautiful Soup.

Amazon web services, Google Data, Google+, YouTube, Twitter, Last.fm, MusicBrainz3, Flickr, LinkedIn, ...



Omrežje z Amazona

!!! zaradi sprememb zgradbe strani ne deluje več

```
Analiza omrežij
```

V. Batagelj

Kako do omrežja?

Rodovnik

Molekule

GraphML

Analiza besedil

Odnosi med

Dvovrstna

Multivariatna

Internet

Slučajn omrežja

\ /:..:

```
amazon <- function(fvtx.flnk.ftit.maxver){</pre>
# ustvari omrezje knjig s spletisca Amazon
  amazon('v.txt', 'a.txt', 't.txt', 10)
# Vladimir Batagelj, 20-21. nov. 2004 / 10. nov. 2006
 opis <- function(line){</pre>
    i <- regexpr('\">',line); l <- i[1]+attr(i, "match.length")[1]</pre>
    j <- regexpr('</a>',line); r <- j[1]-1; substr(line,l,r)</pre>
  vid <- new.env(hash=TRUE,parent=emptyenv())</pre>
 vtx <- file(fvtx,"w"); cat('*vertices\n', file=vtx)</pre>
 tit <- file(ftit, "w"); cat('*vertices\n', file=tit)</pre>
  lnk <- file(flnk, "w"): cat('*arcs\n', file=lnk)</pre>
  url1 <- 'http://www.amazon.com/exec/obidos/tg/detail/-/'
 url2 <- '?v=glance';
  book <- '0521840856'
  auth <- "Patrick Doreian"
  titl <- "Generalized Blockmodeling"
  narc <- 0: nver <- 1
  page <- paste(url1,book,url2,sep='')</pre>
  cat(nver, ' "', book, '" URL "',page,'"\n', sep='', file=vtx)
  cat(nver, ' "', auth, ':\\n',titl, '"\n', sep=',', file=tit)
  assign(book.nver.env=vid)
  cat('new vertex '.nver.' - '.book.'\n')
  books <- c(book)
```



Omrežje z Amazona

Analiza omrežij

V. Batagelj

Kako do omrežja

Rodovnik

Moleku

. . .

Analiza besedi

državami

Dvovrstna omrežia

Multivariatna omrežia

Internet

Slučajni omrežja

Viri

```
while (length(books)>0){
 bk <- books[1]: books <- books[-1]
 vini <- get(bk.env=vid): cat(vini,'\n')</pre>
 page <- paste(url1,bk,url2,sep='')
 stran <- readLines(con<-url(page)): close(con)
 i <- grep("Customers who bought".stran.ignore.case=TRUE)[1]
 if (is.na(i)) break
 j <- grep("Explore Similar Items", stran, ignore.case=TRUE)[1]
 izrez <- stran[i:j]; izrez <- izrez[-which(izrez=="")]</pre>
 izrez <- izrez[-which(izrez=="
 ik <- regexpr("/dp/",izrez); ii <- ik+attr(ik, "match.length")
 for (k in 1:length(ii)) {
   i <- ii[k]:
   if (j > 0) {
      bk <- substr(izrez[k],j,j+9); cat('test',k,bk,'\n')</pre>
      if (exists(bk.env=vid.inherits=FALSE)){
        vter <- get(bk.env=vid.inherits=FALSE)
      } else {
        nver <- nver + 1: vter <- nver: line <- izrez[k]
        assign(bk.nver.env=vid)
        if (nver <= maxver) {books <- append(books,bk)}
        cat(nver,' "',bk,'" URL "',url1,bk,url2,'"\n',sep='',file=vtx)
        cat('new vertex '.nver,' - '.bk,'\n'):
        t <- opis(line); line <- izrez[k+1]
        if (substr(line,1,2)=='by') {a <- substr(line,4,100)}
          else { a <- 'UNKNOWN'
        cat(nver, '"', a, ':\\n', t, '"\n', sep='', file=tit)
     narc <- narc + 1; cat(vini,vter,'\n', file=lnk)</pre>
 flush.console()
close(lnk); close(vtx); cat('Amazon - END\n')
                                                       4日 > 4 周 > 4 目 > 4 目 >
```



Omrežje z Amazona – knjige o analizi omrežij

Analiza omrežij

V. Batageli

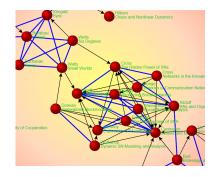
Kako do

Rodovniki

Molekule

Analiza besedil

Internet



Knjige o analizi omrežij z Amazona. 10. november 2006: začetno vozlišče P. Doreian &: Generalized Blockmodeling. Slika SVG. Datoteke/ZIP.

Program v R-ju je le zasnova. Možne izpopolnitve: seznam začetnih vozlišč; nadaljevanje po prekinitvi zveze; ...

Najbrž program danes ni več uporaben, ker se zgradba Amazonovih strani občasno spremeni.



Slučajna omrežja

Analiza omrežij

V. Batageli

Molekule

Analiza besedil

omrežja

Slučajna

Omrežja lahko tudi sami ustvarimo z nekim slučajnim postopkom. Ozadja teh postopkov bomo spoznali kasneje.

Vgrajeni so v Pajka (Network / Create Random network), lahko pa jih tudi sami zapišemo z razmeroma kratkimi postopki v R-ju.

Na voljo je tudi program GeneoRnd za ustvarjanje slučajnih rodovnikov.

Za ustvarjanje slučajnih omrežij, ki pripadajo posebnim razredom omrežij, lahko uporabimo slučajne induktivne razrede [?].



Slučajni neusmerjeni Erdős-Rényijev graf

Analiza omrežij

V. Batageli

Kako do

Molekule

Analiza besedil

Slučajna omrežja

```
dice <- function(n=6){return(1+trunc(n*runif(1,0,1)))}
ErdosRenviNet <-
# generates a random undirected graph of Erdos-Renyi type
# with n vertices and m edges, and stores it on the file
# fnet in Pajek's format.
# Example: ErdosRenyiNet('testER.net',100,175)
# by Vladimir Batagelj, R version: Ljubljana, 20. Dec 2004
# based on ALG.2 from: V. Batagelj, U. Brandes:
    Efficient generation of large random networks
function(fnet,n,m){
  net <- file(fnet, "w"); cat("*vertices", n, "\n", file=net)</pre>
  cat('% random Erdos-Renyi undirected graph G(n,m) / m = '.
    m,'\n',file=net)
# for (i in 1:n) cat(i," \"v",i,"\"\n",sep="",file=net)
  cat("*edges\n",file=net); L <- new.env(TRUE,NULL)
  for (i in 1:m){
    repeat { u <- dice(n); v <- dice(n)
      if (u!=v) {
        edge <- if (u < v) paste(u, v) else paste(v, u)
        if (!exists(edge,env=L,inherits=FALSE)) break }
    assign(edge,0,env=L); cat(edge,'\n',file=net)
  close(net)
```



Dodatni viri

Analiza omrežij

V. Batagelj

Kako do omrežja?

Rodovnik

Molekule

Analiza besedil

Allaliza Deseul

državami

Multivariatna

omrežja

Internet

Slučajna omrežja Viri

Batagelj V., Brandes U.: Efficient Generation of Large Random Networks. Physical Review E 71, 036113, 2005.



Bodlaj, J., Cerinšek, M.: Network Data File Formats. Encyclopedia of Social Network Analysis and Mining. Reda Alhajj, Jon Rokne (Eds.), 2nd Ed, Springer, 2018. PDF



Cerinšek, M., Batagelj, V.: Sources of Network Data. Encyclopedia of Social Network Analysis and Mining. Reda Alhajj, Jon Rokne (Eds.), 2nd Ed, Springer, 2018. PDF



V. Hlebec, T. Kogovšek: *Merjenje socialnih omrežij*. Skripta, Študentska založba, Ljubljana, 2006.



Marsden P.: Network Data and Measurement.



Kejžar, N., Nikoloski, Z., Batagelj, V.: Probabilistic Inductive Classes of Graphs. Journal of Mathematical Sociology 32: 85-109, 2008